

TP: Análisis del Lenguajes- Técnicas – Pipeline

Alumno: Velazquez Wooley Dylan

1. Preparación de los datos (Pipeline)

Para analizar el archivo CorpusLenguajes.txt, armamos una canalización (pipeline) siguiendo los pasos vistos en la teoría. Primero agarramos el texto crudo y lo limpiamos: sacamos las "stopwords" (palabras vacías como is, the, and) y limpiamos signos de puntuación y basura (., "). Después, usamos la lematización con etiquetas POS para llevar las palabras a su forma base real (por ejemplo, que los verbos queden en infinitivo). Con ese corpus ya limpio, calculamos la matriz TF-IDF.

2. Las palabras más y menos usadas Contando las palabras del texto preparado, sacamos la jerarquía del Top 6 de las más usadas en todo el corpus:..

Palabras	Veces q aparece
Python	7
Javascript	7
Cplus	5
Rust	5
Interpret	3
Language	3

En el otro extremo, la palabra menos utilizada no es una sola, sino un grupo de palabras que aparecen 1 sola vez porque son súper específicas (por ejemplo: browser, statically, beginner, nature).

3. Repeticiones en la misma oración Nos fijamos si había palabras que se repitieran dentro de una misma línea para ver dónde se hacía énfasis. Encontramos que:

- En la **Oración 1**, se repite dos veces "**language**" (al comparar lenguajes de alto y bajo nivel).
- En la **Oración 8**, se repiten dos veces "**require**" y "**compilation**" para remarcar cómo funcionan CPlus y Rust en comparación con JavaScript.

4. Análisis de la Matriz TF-IDF Mirando los números que nos devolvió la tabla TF-IDF, pudimos comprobar lo que dice el apunte sobre esta técnica. Aunque "python" es la palabra que más se nombra en todo el archivo, el algoritmo le da un "peso" re bajo en la matriz (valores cerca de 0.17). En cambio, palabras que casi no aparecen pero que son claves para entender una oración en particular (como "language" en la Oración 1, que saca 0.64 de peso) reciben los puntajes más altos. osea, el TF-IDF penaliza a las palabras que están en todos lados porque no te ayudan a diferenciar una oración de otra.

5. Gráfico de Distribución de Frecuencias

